

Вариант	Автообработка	Операторы OPEX	LLM OPEX	Retrieval OPEX	Backend CAPEX	Backend OPEX	Итого ориентир/мес	Из чего складываются затраты
0. Текущая ручная обработка	0%	3.5 млн ₽	0	0	0	0	3.5 млн ₽	Все обращения обрабатываются вручную. Основная статья расходов — ФОТ операторов. ИТ-система практически отсутствует либо используется только как CRM/почта.
1. Матрица П×С×Т×П (продукт, сценарий, тональность, приоритет)	80–90%	350–700 тыс ₽	0	0	70–140 тыс ₽	30–60 тыс ₽	450–900 тыс ₽	Требуется разработка и сопровождение большой матрицы правил. Операторы работают только с исключениями. Основные расходы: поддержка бизнес-правил, администрирование справочников, разработка логики при появлении новых продуктов и сценариев. Backend CAPEX: разработка API, БД, операторской консоли, административного интерфейса, механизма правил и справочников. Backend OPEX: VPS, PostgreSQL, резервное копирование, мониторинг, техническая поддержка инфраструктуры.
2. LLM-first	85–95%	200–500 тыс ₽	30–50 тыс ₽	0	100–170 тыс ₽	50–80 тыс ₽	380–800 тыс ₽	LLM выполняет классификацию и генерацию ответов. Затраты: API модели, мониторинг качества, операторы для контроля ошибок, инфраструктура для хранения истории и логирования. Главный риск — зависимость бизнес-решений от поведения модели. Backend CAPEX: интеграция с LLM-провайдерами, управление промптами, хранение истории запросов и ответов, аудит решений модели, механизмы fallback. Backend OPEX: серверы, БД, хранение логов, мониторинг, сопровождение интеграций с AI-сервисами.
3. Retrieval-first	85–95%	200–500 тыс ₽	0–10 тыс ₽	10–30 тыс ₽	100–170 тыс ₽	50–80 тыс ₽	360–790 тыс ₽	Основа системы — база типовых ситуаций и поиск похожих обращений. LLM либо отсутствует, либо используется минимально. Затраты: сопровождение базы знаний, поиск (pgvector/Chroma/Weaviate), операторы для новых кейсов. Backend CAPEX: разработка базы типовых ситуаций, индексации, механизмов поиска и интерфейсов управления знаниями. Backend OPEX: инфраструктура PostgreSQL/векторного поиска, хранение индексов, резервное копирование, мониторинг и сопровождение базы знаний.
4. Полный RAG	85–95%	200–500 тыс ₽	40–80 тыс ₽	20–50 тыс ₽	130–200 тыс ₽	70–100 тыс ₽	460–930 тыс ₽	Используются документы, инструкции, регламенты, база знаний и LLM. Самая технологически сложная схема. Затраты: векторная БД, индексация документов, API моделей, инфраструктура для RAG-контура и контроля качества retrieval. Backend CAPEX: обработка документов, chunking, embeddings, индексация, RAG-конвейер, управление знаниями и аналитика качества поиска. Backend OPEX: серверы, хранение индексов и эмбеддингов, мониторинг retrieval, обслуживание RAG-контура и базы знаний.
5. Controlled Hybrid	90–98%	70–350 тыс ₽	10–30 тыс ₽	10–30 тыс ₽	130–200 тыс ₽	70–100 тыс ₽	290–710 тыс ₽	База типовых ситуаций является SOT. Retrieval определяет наиболее подходящую ситуацию. LLM используется для адаптации текста, а не для принятия бизнес-решения. Операторы работают только с новыми или спорными случаями. Основные расходы: поддержка базы знаний, инфраструктура платформы, минимальное потребление LLM. Backend CAPEX: разработка платформы управления типовыми ситуациями, шаблонами ответов, правилами маршрутизации, аудитом решений и операционной аналитикой. Backend OPEX: серверы, БД, retrieval-контур, мониторинг, резервное копирование, эксплуатация платформы и сопровождение базы знаний.